Stable Diffusion理解与代码解读

2023-03-01 016:55




图3. 不同生成模型对比图 (来源: Lil博客)

diffusion的latent尺寸和原始尺寸一致

Denoising diffusion probabilistic models (DDPM)




图4. diffusion的前向(q)和逆向(p)过程,来源: DDPM

在所有的时间T

$$q(x_t|x_0) = \mathcal{N}\Big(x_t; \sqrt{ar{lpha}_t}x_0, (1-ar{lpha}_t)\mathbf{I}\Big)$$

Loss推导

Simplified loss


$$L_{ ext{simple}}(heta) = \mathbb{E}_{t,x_0,\epsilon} igg[\left\| \epsilon - \epsilon_{ heta}(\sqrt{ar{lpha}_t}x_0 + \sqrt{1-ar{lpha}_t}\epsilon,t)
ight\|^2 igg]$$

逆向过程

1607/170

1607/1710

- 1) 每个时间步通过 x_t 和t 来预测高斯噪声 $z_{\theta}(x_t,t)$,随后根据(9)得到均值 $\mu_{\theta}(x_t,t)$.
- 2) 得到方差 $\Sigma_{\theta}(x_t,t)$,DDPM中使用untrained $\Sigma_{\theta}(x_t,t)=\tilde{eta}_t$,且认为 $\tilde{eta}_t=eta_t$ 和 $\tilde{eta}_t=rac{1-ar{lpha}_t-1}{1-ar{lpha}_t}\cdoteta_t$ 结果近似,在GLIDE中则是根据网络预测trainable方差 $\Sigma_{\theta}(x_t,t)$.
- 3) 根据(5-2)得到 $q(x_{t-1}|x_t)$,利用重参数得到 x_{t-1} .



在x0和xt反复横跳的diffusion逆向过程

Algorithm 1 Training

1: repeat

2: $\mathbf{x}_0 \sim q(\mathbf{x}_0)$

3: $t \sim \text{Uniform}(\{1, \dots, T\})$

4: $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$

5: Take gradient descent step on

$$\nabla_{\theta} \left\| \boldsymbol{\epsilon} - \mathbf{z}_{\theta}(\sqrt{\bar{\alpha}_t}\mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t}\boldsymbol{\epsilon}, t) \right\|^2$$

6: until converged

Algorithm 2 Sampling

1: $\mathbf{x}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$

2: **for** t = T, ..., 1 **do**

3: $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ if t > 1, else $\mathbf{z} = \mathbf{0}$

4: $\mathbf{x}_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{1-\alpha_t}{\sqrt{1-\bar{\alpha}_t}} \mathbf{z}_{\theta}(\mathbf{x}_t, t) \right) + \sigma_t \mathbf{z}$

5: end for

6: return \mathbf{x}_0

知乎 @ewricas

DDPM训练测试算法流程图 (来源: DDPM)

DDPM简单训练代码

ref:

https://github.com/w86763777/pytorch-ddpm.git.

https://github.com/hojonathanho/diffusion

https://nn.labml.ai/diffusion/ddpm/index.html

■ 模型

- Unet with
 - time embedding (t→embedding by sin/cos(t*pos) and linear)
 - downSample + Resblock(attentBlock) + upsample
- 保证输入输出一致

Gaussian Diffusion Trainer

- beta_1, beta_T, T: 初始beta/最后beta/时间stepT
- beta在1~T中插值, alpha=1-alpha
- alpha_bar = cumprod(alpha), 求出sqrt(a_bar) / sqrt(1-a_bar)

```
def forward(self, x_0):
    """
    Algorithm 1.
    """
    t = torch.randint(self.T, size=(x_0.shape[0], ), device=x_0.device)
    noise = torch.randn_like(x_0)
    x_t = (
        extract(self.sqrt_alphas_bar, t, x_0.shape) * x_0 +
        extract(self.sqrt_one_minus_alphas_bar, t, x_0.shape) * noise)
    loss = F.mse_loss(self.model(x_t, t), noise, reduction='none')
    return loss
```

extract就是获取对应的time t

- 每一步的训练是随机找一个 $t,\, ar{x}$ 出 $X_t = \sqrt{ar{lpha_t}} x_0 + \sqrt{1-ar{lpha_t}} ar{z}_{t}$,判断与noise的区别
- Gaussian Diffusion Sampler
 - 从Xt(高斯nosie) 恢复成为X0(原图)的逆过程

$$rac{1}{\sqrt{lpha_t}} \Big(x_t - rac{eta_t}{\sqrt{1-ar{lpha_t}}} \epsilon_ heta(x_t,t) \Big)$$

■ ddpm操作步数多, ddim优化了它

Stable diffusion

= VAE + latent space diffusion + conditioning

ref:

https://zhuanlan.zhihu.com/p/581225163

https://zhuanlan.zhihu.com/p/583124756

https://www.high-flyer.cn/blog/stable-diffusion/


https://zhuanlan.zhihu.com/p/591432516

■ 原本的DDPM是一个Image to Image的模型, 通过noise生成结果. sd是加入condtional input, 跨模态进行输出



- 在latent space进行diffusion可以大大降低迭代的step数量 (LDM)
- 通过引入一个领域内的编码器,将图片进行condition的生成(Unet的每一层都加入了condition)
- 输入的模态可以有 image, segement, depth, text等等
- 首先要训练一个vae模型, 在latent space上进行diffusion操作(比如在imagenet上训练)
- diffusion变成了如何从noise生成latent code, 然后通过解码器恢复图像

核心是一个latent diffusion model



■ 核心的context融合, 通过将latent space的z和condition的z通过attention进行融合, 然后在进行去噪声的过程

ControlNet

ref:

https://zhuanlan.zhihu.com/p/609075353

https://zhuanlan.zhihu.com/p/605761756



- 通过另一个网络实现对原本sd模型的微调
- 相当于把text prompt的condition 替换成了其他depth/seg/edge的引导. 最重要的是统一了所有不同的输入